

2026年主流AI赛道顶会标准Benchmark与公平对

比自查表

— 杜绝数据集陷阱，避开 Direct Reject —

著作人：科研华哥

第1部分 数据集合规性与审稿人心理

1.1 审稿人如何判定你的实验"不合规"?

在顶会审稿中，实验部分 (Section

4) 被拒稿的最常见原因并非"指标不够高"，而是"对比不公平 (Unfair Comparison)"。常见的雷区包括：

1. 数据切分 (Data Split) 私自篡改：未沿用官方 Train/Val/Test 划分。2. 选择性忽略最新 Baseline：故意漏掉近两年同方向在一区/顶会发表的 SOTA。3. 参数量/计算量不对等：用 100M 参数量的模型去欺负 10M 参数量的 Baseline。

1.2 公平对比的"黄金三大准则"

同等骨干网络 (Same Backbone)： CV 赛道统一为 ResNet-50 / Swin-B；NLP 赛道统一为 Llama-3-8B / Qwen2.5-7B。

同等数据输入 (Same Resolution / Context Length)： 分辨率与输入长度必须强制对齐。

多次随机种子 (Multiple Seeds)： 至少报出 3-5 次运行结果的"均值 $\pm$ 标准差"。

第2部分 四大主流AI赛道必跑Benchmark指南

2.1 计算机视觉 (CV: Detection, Segmentation & Generation)

核心必跑数据集：

- 目标检测/分割：COCO 2017 (Standard Split), ADE20K, Cityscapes.
- 图像生成/重建：ImageNet-1K, FFHQ (512x512/1024x1024).

必须报出的评估指标： mAP@0.5:0.95, mIoU, FID, CLIP-Score, Flops (G), Params (M).

防踩雷提醒： 禁止使用 Voc2012 小型数据集作为主实验；禁止不标明 Backbone 规模。

2.2 自然语言处理与大模型 (NLP & LLMs)

核心必跑数据集：

- 综合推理与能力：MMLU, GSM8K, MATH, HumanEval.
- 长文本与长上下文：L-Eval, Needles in a Haystack (Haystack).

必须报出的评估指标：Accuracy (%), Pass@1, Bleurt, Perplexity (PPL).

防踩雷提醒：必须在附录明确声明 Prompt 模板；禁止将测试集样本混入 SFT 数据集。

2.3 图机器学习 (Graph Machine Learning)

核心必跑数据集：

- 节点分类与图分类：OGB (ogbn-arxiv, ogbg-molhiv, ogbn-papers100M).
- 异质图与时序图：Reddit, Amazon-Photos, TKG Datasets.

必须报出的评估指标：ROC-AUC, Micro-F1, Macro-F1.

防踩雷提醒：禁止仅使用 Planetoid (Cora, Citeseer, Pubmed)

三个微型数据集作为主论据！顶会审稿人视其为玩具数据集 (Toy Dataset) 。

2.4 多模态与跨模态 (Multimodal AI)

核心必跑数据集：

- 图文理解与问答：MMBench, SEED-Bench, ScienceQA.
- 视频与音频：ActivityNet, Ego4D, AudioCaps.

必须报出的评估指标：Top-1 Accuracy, CIDEr, SPICE.

防踩雷提醒：跨模态对齐实验中，必须严格区分 Zero-shot 与 Fine-tuned 条件。

第3部分 实验部分送审前10项自查清单

3.1 送审前勾选自查表 (Checklist)

- ☐ 1. 我的 Main Table 中是否包含了近 2 年 (2024-2026) 至少 3 篇顶会/顶刊 Baseline?
- ☐ 2. 所有的指标对比，是否均已标注粗体 (最高) 与下划线 (次高) ?
- ☐ 3. 是否在表格下方脚注中明确标出了显卡型号与训练耗时?
- ☐ 4. 消融实验 (Ablation Study) 中，是否每一个模块都具备"独立剔除"的对比行?
- ☐ 5. 是否针对超参数 (如 Loss 权重 λ) 画出了敏感度曲线 (Sensitivity Curve) ?
- ☐ 6. 是否展示了至少 1 组 Failure Cases (失败案例) 并给出了合理分析?
- ☐ 7. 代码与数据划分脚本，是否已整理并上传至匿名 GitHub / Anonymous Repo?
- ☐ 8. 是否在不同随机种子 (Seed=42, 123, 2026) 下跑出了标准差?
- ☐ 9. 参数量 (Params) 与计算量 (FLOPs) 是否与 Baseline 进行了显式对比?
- ☐ 10. 是否在论文中明确声明了所使用的预训练权重 (Pre-trained Weights) 来源?

写作提醒

自查表不是摆设，每一条都对应审稿人的典型拒稿理由。建议打印出来贴在工位上，每篇论文投出去之前逐条核对。

顶会的竞争越来越激烈，实验的规范性往往决定了论文是进入 Minor Revision 还是 Direct Reject.